Notes sur le Lab 1

Antoine POIRIER ING5 DEF

October 29, 2026

Où peuvent s'infiltrer les instructions douteuses ?

Ces instructions peuvent s'imiscer dans le système IA de deux façons principales : soit de manière directe grâce à des prompts utilisateurs néfastes (direct prompt injection), soit indirectement par le biais des sources de données qui ne proviennent pas directement de l'utilisateur mais plutôt des plugins et/ou datasets utilisés par le LLM (indirection prompt injection).

Quelles mesures ont changé le résultat ?

La suppression d'expressions impératives et le rétrogradage des privilèges ont permit de réduire les risques liés notamment à l'agence excessive du modèle et aux injections.

Les risques identifiés

Risque	OWASP	MITRE ALIAS
Tentative injection pour obtenir les accès admin.	LLM01	AML.T0051
Affichage des authentifiants admin	LLM02	AML.T0098
Traitement des sorties non-sécurisé	LLM02	AML.T0135
Privilèges excessives confiés au modèle	LLM08	AML.T0053
Tentative direct de jailbreak	LLM01	AML.T0054